吴昌松的简历

基本信息

- **姓名**：吴昌松
- **出生年月**：1990
- **联系方式**：15057102157
- **Email**：sdupine@126.com

教育背景

- 2007 - 2011：山东大学 软件学院 软件工程
- 2011 - 2014：山东大学 计算机科学与技术学院 计算机体系结构

工作经历

- 2014.07 - 2021.01: 阿里巴巴 - YunOS(AliOS)自研OS开发
- 2021.01 - 2022.04: 阿里巴巴 - 斑马智行AI编译及加速
- 2022.04 - 至今 : 理想汽车 - 自研AI推理芯片编译栈及大模型部署优化

工作项目介绍

[2022.05 - 至今 理想汽车] 深度参与自研AI推理芯片研发，算子编译器和高性能算子库负责人

- 深度参与理想自研AI推理芯片研发，分析软件需求，协助架构确定AI芯片规格
- 基于MLIR构建AI编译栈，负责算子编译器部分，实现MLIR到自研芯片的代码生成和优化；支撑智驾模型部署编译，满足精度和性能目标
- 负责LLM大模型推理优化部署，基于自研芯片架构特性深度优化，实现性能超越竞品
- 负责自研芯片高性能算子库开发，深度优化并与编译栈集成，实现性能目标
- 支撑交付理想智驾模型基于自研芯片上车

[2021.01 - 2022.04 阿里斑马] 基于TVM深度学习编译器加速网络，独立负责高通Hexagon CDSP平台加速支持

- 在TVM中增加高通Hexagon CDSP后端支持，编译阶段添加compute和schedule，调整优化Hexagon runtime；
- 支持已量化模型直接编译为CDSP指令，端到端在CDSP上运行完整模型，精度保持一致；
- 基于TVM tensorize机制，添加CDSP HVX汇编优化kernel，实现对conv2d/depthwise_conv2d/avg_pool等算子加速；
- 基于TVM BYOC机制，将TVM编译模型对接到Hexagon NNlib库，实现与高通SNPE推理引擎接近的性能；但能更好支持后量化模型；
- 熟悉Hexagon DSP/HVX 硬件架构和核心向量加速指令；

[2019.07 - 2019.12 阿里] 基于ARMv8架构的车机平台Hypervisor开发，支持RTOS+多Linux运行

- 基于Hafnium开发实现了面向ARMv8架构的车机Hypervisor，支持RTOS+多个Linux同时运行；

- 参与负责整个Codebase选型，基于Qemu的bringup和调试，VMs管理架构设计，vCPU调度管理机制，中断注入管理，RTOS隔离策略等设计；
- 实现Hypervisor的Primary VM(一个简单的OS kernel)，以线程化方式对其他VM的vCPU进行管理调度；解决Primary VM 中timer，中断等关键问题；
- 开发实现VM的Timer IRQ管理，vGIC中断管理，PPI/SPI/SGI虚拟中断注入等关键流程，以及vCPU线程调度等；

[2017.12 - 2011.11 阿里] 开发AliOS系统的车牌定位及字符识别深度学习模型

- 基于Intel LPRNet使用TensorFlow深度学习框架，实现了车牌的定位模型、车牌字符识别模型；前端对接车辆识别定位网络，后端对接车辆ID；
- 算法来源于论文中的结构进行调整；自建车牌定位训练数据库，车牌字符识别训练数据库，进行训练；
- 性能及准确率：在Nvidia RTX2080平台（未优化），车牌定位延迟20ms，定位完整率95%；车牌字符识别延迟25ms，识别准确率98%；

[2018.12 - 2019.10 AliOS] 开发AliOS端上深度学习推理Benchmark框架及部分算法模型

- 为了对AliOS的深度学习推理框架进行评测，合作开发网络模型Benchmark进行性能评测；
- 分析调研了业界的各类深度学习网络模型，选取了各个领域里最具代表性和实用性的模型作为评测算法；选择评测指标和打分机制，且基于TensorFlow实现了算子性能热点分析工具；
- 基于开源论文复现并使用TensorFlow实现了其中的语音转文字算法，包括DeepSpeech和WaveNet；
- 基于AliOS JS App实现了前台可视化应用，将评测结果实时可视化；

[2019.11 - 2020.03 斑马] 车机系统功能安全调研以及形式化验证调研实践

- 调研汽车行业的Safety标准(ISO26262)以及ASIL定级，目的是支撑如何开发符合安全标准的车机系统；
- 形式化验证方法的调研实践，对业界各种形式化方法进行梳理对比；
- 重点对TLA+的形式化验证方法进行调研，能够编写TLA+ spec对独立模块的并发正确性进行验；

[2015.06 - 2017.10 AliOS] 开发并维护AliOS Audio Framework音频架构

- 合作开发实现AliOS的自己的音频服务框架，实现音频各类服务包括playback，recording，音量调节，多设备输出，混音，音频焦点管理等；
- 基本架构包括native service，native client，JS-addon以及JS API；采用socket作为IPC；底层对Audio HAL及ALSA接口；
- 实现对Android音频框架的兼容，通过Virtual Audio HAL机制接管Android的所有音频数据和控制流，体验统一无缝；
- 设计实现音频焦点策略，以支持多种音源(音乐/导航/通话/警告/...)播放优先级及冲突策略；面向多种产品形态，策略可配置；同时兼容Android应用的AudioFocus融合；
- Audio框架的稳定性维护，低延迟优化，underrun/overrun问题分析解决

[2014.11 - 2018.11 AliOS] 开发维护AliOS复用Android硬件生态及Bionic库，实现AliOS的HAL管理层

- 参与AliOS新版本的bringup，实现在AliOS中通过Container方式运行Android系统
- 基于LibHybris实现在AliOS中复用Android硬件生态，即在AliOS中运行Android Vendor闭源硬件抽象库(HAL)；同样支持在AliOS GLibc环境中运行Android Bionic库
- 设计实现Virtual HAL(vHAL)机制接管Android对硬件的访问，以达到AliOS主控硬件并融合Android的目的

- 设计实现AliOS自身HAL统一加载和管理库libhal，用于统一Native service对HAL库的加载方式，达到解耦目的

[2014.07 - 2014.11 AliOS] YunOS3.0系统手机录屏功能开发

- 基于Android Framework增加录屏功能，从SurfaceFlinger获取屏幕framebuffer，从Mic获取录音，结合Mediacodec编码为MP4视频
- 实现屏幕录制、录音、手动/自动暂停恢复、通知栏快捷入口，视频分享等特性
- 支持安全录屏，自动跳过密码输入、支付宝敏感界面
- 对Android Framework修改的稳定性验证

基本技能

- 熟悉Linux环境开发，C/C++；会使用Python，TensorFlow，OpenCV
- 了解Android Framework
- 了解Linux kernel(Timer，中断，调度)及虚拟化技术(KVM, Hafnium)
- 了解计算机体系结构，熟悉ARM架构嵌入式系统
- 了解深度学习及框架，能够实现，训练，调整网络模型
- 熟悉深度学习编译器MLIR，以及面向特定硬件架构的优化加速